POSIM：基于元认知智能体的通用社交媒体舆情仿真框架

作者信息（待补充）

***Abstract*—社交媒体上的舆情事件可在数小时内引发大规模群体参与，理解并预判其演化过程对社会治理与危机应对具有重要价值。然而，现有仿真方法面临认知建模粗粒度、时间动力学失真和验证体系不完整三重挑战，难以忠实再现真实舆情的复杂动态。本文提出通用社交媒体舆情仿真框架 POSIM（Public Opinion Simulator），将大语言模型嵌入 EBDI（融合情感的信念-欲望-意图）分层认知框架，构建具有显式认知状态和可追溯推理链的元认知智能体。在仿真环境层面，框架采用霍克斯自激点过程统一建模外生事件冲击与内生用户交互，结合推荐算法与热搜榜单模拟，实现分钟级粒度的长周期高保真仿真。进一步地，框架建立了从微观机制校准到宏观涌现校准再到统计一致性校准的三层递进验证体系。在三个大规模真实微博舆情事件数据集上的实验表明，POSIM 在行为分布、内容特征和网络拓扑三个层面均优于基线方法，且能自发涌现出情绪极化、无标度拓扑和信息级联幂律等与社会科学理论一致的宏观现象。此外，认知引导和反事实策略干预实验展示了框架在因果推理和舆情治理策略评估方面的应用价值——仿真中首次定量观察到共情悖论效应，并为危机公关策略的优选提供了实证依据。**

***Index Terms*—社交媒体仿真，舆情分析，大语言模型，智能体认知架构，霍克斯过程**

I. 引言

社交媒体已成为公共舆论形成与传播的核心场域。在社交媒体平台上，一则突发事件可在数小时内引发数百万用户的参与讨论，形成复杂的群体情绪动态和信息级联效应。理解和预判舆情演化规律对社会治理、危机应对和公共政策制定具有重要的现实意义 。然而，真实世界的社会实验面临伦理约束、不可重复性和变量不可控等根本性困难，使得基于计算机仿真的实验方法成为兼具科学严谨性和实践可操作性的研究路径 。

构建高保真的社交媒体舆情仿真系统面临三重核心挑战。第一，**认知建模挑战：**社交用户的行为决策充满非理性因素，受情绪驱动、认知偏差和社交影响等多重因素交互作用 ，如何使仿真智能体基于信念、情感和动机进行类人的非理性决策，而非作为简单的规则执行器或黑箱文本生成器，是实现微观行为保真度的前提。第二，**时间动力学挑战：**真实舆情事件中用户互动发生在分钟甚至秒级时间尺度——一条爆炸性新闻可在数分钟内引发数千条转发，而在事件间歇期活跃度则大幅回落——这种高度不均匀的时间分布对仿真的时间分辨率和计算效率提出了双重要求。第三，**验证闭环挑战：**仿真系统的可信度依赖于系统性的多层次验证，既需要校验微观决策机制的合理性，又需要验证宏观涌现现象的一致性，还需要与真实数据进行统计层面的定量比对。

表 **??**对比了 POSIM 与现有代表性舆情仿真平台在关键能力维度上的差异。POSIM 是首个同时具备认知机制建模、分钟级时间精度、真实数据评估、多策略推演支持和可扩展性的通用舆情仿真框架。

基于智能体的建模（ABM）方法因其天然适配社会系统自下而上涌现特性的优势，在舆情仿真中获得了广泛应用 。经典的观点动态模型通过预定义的数值型交互规则刻画了个体观点在社交影响下的收敛、分裂和极化过程 。然而，规则驱动的智能体无法生成真实的文本内容，仿真输出停留在数值层面，且固定规则难以覆盖人类认知决策的复杂性。近年来，大语言模型（LLM）的突破为社会仿真注入了新的可能性。以生成式智能体 为代表的研究证明了 LLM 驱动的智能体具备涌现复杂社会行为的潜力，后续工作进一步探索了 LLM 智能体在舆情仿真中的应用 。然而，多数现有工作将 LLM 作为端到端的行为映射器——直接从环境输入映射到行为输出——缺乏显式的中间认知状态建模，决策过程不可解释、不可追溯，且长周期仿真中智能体的人格一致性难以保证。

TABLE I
POSIM 与现有舆情仿真平台的能力对比

平台	认知机制	时间精度	真实数据验证	策略评估	可扩展性	多类智能体
HiSim	×	⋆⋆	✓	×	⋆⋆	✓
LMAgent	×	⋆⋆	✓	×	⋆⋆	✓
SPARK	×	⋆⋆	×	×	⋆⋆	✓
S3	×	⋆⋆⋆	✓	×	⋆⋆⋆	×
FDE-LLM	×	⋆⋆	✓	×	⋆⋆	✓
TrendSim	×	⋆⋆⋆⋆	×	×	⋆⋆⋆	✓
OASIS	×	⋆⋆⋆⋆	×	×	⋆⋆⋆⋆	×
GA-S3	×	⋆⋆⋆	✓	×	⋆⋆	✓
POSIM (Ours)	✓	⋆⋆⋆⋆⋆	✓	✓	⋆⋆⋆⋆⋆	✓

注：⋆ 数量表示能力等级（1–5）。✓ = 支持，× = 不支持。认知机制指显式 BDI 建模；时间精度指最细时间粒度与动态激活；策略评估指反事实干预支持。

为应对上述挑战，本文提出社交媒体舆情仿真框架 POSIM（**P**ublic **O**pinion **Sim**ulator）。该框架的核心思想是将 LLM 作为认知推理引擎嵌入基于 EBDI（Emotion-augmented Belief-Desire-Intention）的分层认知架构 ，构建具备显式认知状态和可追溯推理链的元认知智能体。在仿真环境层面，框架采用霍克斯自激点过程 建模群体活跃强度的时间动力学，并辅以多维度推荐算法和热搜榜单模拟，实现分钟级粒度的长周期高保真仿真。在验证层面，框架提出从微观机制校准到宏观涌现校准再到统计一致性校准的三层递进验证方法论。本文的主要贡献概括如下：

（1）提出元认知智能体架构，将 LLM 引入 EBDI 分层认知框架，构建了从感知、信念、欲望、意图到行为的完整认知链路。该架构通过层次化信念体系（角色身份、心理认知、事件观点、情绪激发四层信念）实现认知状态的显式建模与动态更新，通过多级思维链的意图规划实现可解释的行为生成，使每一步决策均可追溯至具体的认知状态变化。

（2）设计时间-事件混合驱动仿真环境，基于霍克斯自激点过程将外生舆情事件与内生用户交互统一纳入连续时间建模框架，辅以推荐算法和热搜榜单模拟，使仿真的时间动态特性由数据驱动的点过程参数控制，而非依赖人工设定的固定时间步长。

（3）在三个大规模真实微博舆情事件数据集上进行了系统性的三层验证，并通过认知引导实验和反事实策略干预实验展示了框架在因果推理和舆情治理策略评估方面的应

通讯作者信息（待补充）。

用价值，为舆情治理策略的定量评估提供了完整的实验闭环。

本文其余部分组织如下：第??节回顾相关工作；第??节介绍 POSIM 框架设计；第??节报告实验结果；第??节展示案例研究；第??节总结全文。

II. 相关工作

社交媒体舆情仿真研究主要经历了三个发展阶段。早期研究多基于传染病模型（如 SIR）和观点动力学模型（如 DeGroot、HK 模型），侧重于宏观传播趋势的数学描述，但往往忽略了微观个体的异质性与认知复杂性。随着大数据技术的发展，基于点过程（如霍克斯过程）的数据驱动方法显著提升了时间动力学的拟合精度，但难以解释行为背后的心理机制。

基于智能体的建模（ABM）通过自下而上的交互模拟涌现现象，成为社会仿真的主流范式。然而，传统 ABM 依赖预定义规则，无法生成语义丰富的文本内容。近期，大语言模型（LLM）的引入为社会仿真带来了革命性突破。生成式智能体具备了强大的自然语言理解与生成能力，能够模拟更逼真的社交互动。

尽管现有 LLM 驱动的仿真系统在行为拟合上取得了进展，但仍存在显著局限：一是缺乏显式的认知状态建模，决策过程常为黑箱；二是时间粒度较粗，难以捕捉舆情的瞬时爆发特性；三是缺乏系统的多层级验证体系。POSIM 框架针对这些问题，提出了融合 EBDI 认知架构与霍克斯过程的元认知智能体仿真方案，旨在实现微观可解释与宏观高保真的统一。

III. POSIM 框架

本节详细介绍 POSIM 框架的三个核心组件：元认知智能体架构（第??节）、仿真环境（第??节）和策略推演框架（第??节）。图 ??展示了框架的整体架构。

A. 问题定义

社交媒体舆情仿真的目标是：给定一组初始用户群体 $\mathcal{U}$、事件背景 $\mathcal{B}$ 及外部事件序列 $\mathcal{E} = \{e_1, e_2, \ldots, e_K\}$，在虚拟社交媒体平台上模拟用户群体在舆情事件中的行为演化过程 $\{A_t\}_{t=0}^{T}$，使得仿真产生的宏观统计特征（行为分布、情感动态、网络拓扑等）与真实舆情数据具有统计一致性，同时智能体的微观决策过程具备认知可解释性。

B. 元认知智能体架构

传统的反应式智能体遵循简单的感知–行动范式，仅作为无状态的行为生成器，无法捕捉人类决策中涉及信念修正、动机权衡和策略选择的复杂认知机制。考虑到社交媒体用户的行为决策受情绪驱动、认知偏差和社交影响等多重非理性因素的交互作用，我们提出融合情感因素的元认知智能体架构。元认知体现在两个层面：其一，智能体具有显式的自我认知状态（信念、情绪、动机），每一步决策均基于可观测的认知状态变化；其二，智能体的认知过程本身是可审计的多阶段推理链，而非单次黑箱调用。认知流程形式化为：

$$\begin{aligned}\text{Perception}(P_t) &\rightarrow \text{Belief}(B_t) \rightarrow \text{Desire}(D_t) \\ &\rightarrow \text{Intention}(I_t) \rightarrow \text{Action}(A_t) \quad (1)\end{aligned}$$

该架构以 LLM 为认知推理引擎，包含信念子系统、欲望子系统和意图子系统三个核心模块。三个子系统在每个决策周期内依次运行，各自接收上游输出作为输入，形成从环境感知到行为输出的完整且可追溯的认知链路。

1) 信念子系统: 信念是智能体对外部世界和自身状态的动态认知表征，构成一切决策推理的基础。社会心理学研究表明，个体的不同认知层次具有不同的稳定性 ——核心人格特质在短期内高度稳定，而对特定事件的观点和即时情绪则随信息输入快速变化。基于这一认知分层特性，我们设计了层次化的信念体系 $B = \langle B^{id}, B^{psy}, B^{evt}, B^{emo} \rangle$，四类信念按认知修正难度从高到低排列。

角色身份信念 B^{id} 表征智能体的固有基础认知，包括人口学属性（性别、地域）、社交属性（粉丝规模、认证类型）和身份属性（职业、兴趣标签）等，在仿真周期内保持恒定。例如，“我是一名拥有 10 万粉丝的微博认证博主，关注领域为社会时事”。初始化时，从真实社交媒体平台采集用户的基础信息及历史发布内容，利用 LLM 进行结构化推断，以第一人称自述的自然语言形式生成角色身份描述。该信念在仿真过程中不会更新，作为智能体人格一致性的锚定层。

心理认知信念 B^{psy} 表征智能体在舆情参与中的深层心理特征与认知倾向。社会心理学研究表明，网民在面对网络事件时表现出从众、成见、冲动、偏执等典型心理现象。基于对多起真实舆情事件中用户行为模式的分析，我们将网民心理特征归纳为以下典型模式：自我实现型（追求社会认同与自我价值实现）、猎奇探究型（对新奇事件保持高度关注）、减压宣泄型（将网络空间视为情绪释放渠道）、仇官仇富型（对权力与财富持有负面预设）、跟风从众型（倾向于追随主流意见）等。心理认知信念以结构化文本列表形式存储，每条信念为一个具体的认知倾向描述，如“主流媒体未报道的往往才是真相”“富人的财富来源存疑”等。初始化时，基于采集的真实用户历史内容，通过 LLM 从预定义的心理特征池（涵盖八类典型网民心理模式，每类约 30 条代表性条目）中进行个性化采样与适配。心理认知信念在仿真过程中保持高度稳定，仅在极端情境下可能发生微调，反映了深层心理特质的抗变性。

事件观点信念 B^{evt} 表征智能体对特定舆情事件中各参与主体的事实认知、背景理解和观点立场。与前两类信念不同，事件观点信念随舆情发展动态演化——新信息的摄入、他人观点的影响和事件进展均可能导致观点的修正或强化。每条事件观点采用结构化四元组表示：$\langle t, \text{subject}, \text{opinion}, \text{reason} \rangle$，其中 t 为观点形成时间，subject 为评价主体（如涉事人物、机构等），opinion 为当前观点立场，reason 为支持该观点的理由。初始化时，基于用户在事件爆发前的历史发布内容，通过 LLM 驱动的结构化深度访谈机制（如提问“对于涉事主体 X，你当前的观点是什么？”）提取用户对各参与主体的初始观点倾向。

情绪激发信念 B^{emo} 基于认知行为理论中的 ABC 模型，强调认知评价对情绪反应和后续行为的中介作用。情绪周期现象是后真相时代网络舆情的显著特征——事件初期的情绪爆发、中期的情绪传染与极化、后期的情绪衰减构成了完整的情绪动力学过程。为建模这一过程，我们采用 Ekman 的六维基本情感分类框架，将情绪状态表征为连续向量 $\mathbf{e} = [e_{hap}, e_{sad}, e_{ang}, e_{fear}, e_{sur}, e_{dis}]^\top \in [0,1]^6$，分别对应快乐、悲伤、愤怒、恐惧、惊讶和厌恶六种基本情绪。情绪状态的更新受三个机制驱动：（1）**时间衰减**——参照心理学中情绪的自然消退规律，情绪强度随时间

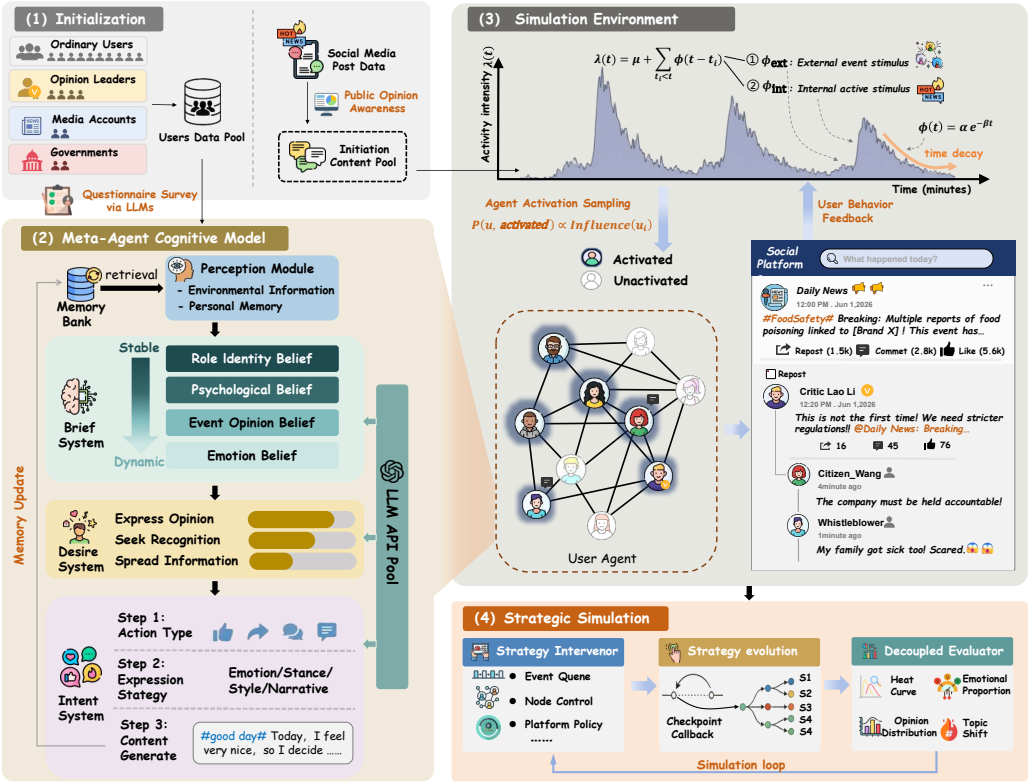

Fig. 1. POSIM 框架总体架构。左侧为元认知智能体架构，包含信念、欲望和意图三个认知子系统；中间为仿真环境，包含霍克斯点过程驱动的时间引擎、推荐系统和热搜榜单；右侧为策略推演框架，支持事件注入、信念干预和反事实分支。

按指数衰减：$\mathbf{e}_i(t) = \mathbf{e}_i(t_0) \cdot e^{-\lambda_e(t-t_0)}$，其中 λ_e 为衰减系数；（2）**内容刺激**——智能体浏览的推荐内容中蕴含的情感色彩对其情绪产生增量影响：$\mathbf{e}_i \leftarrow \mathbf{e}_i + \eta \cdot \mathbf{s}_{content}$，其中 $\mathbf{s}_{content}$ 为内容的情感向量，η 为影响系数；（3）**社交传染** ——智能体的情绪受其社交邻居的情绪状态影响：$\mathbf{e}_i \leftarrow (1-\rho) \cdot \mathbf{e}_i + \rho \cdot \bar{\mathbf{e}}_{neighbor}$，其中 $\bar{\mathbf{e}}_{neighbor}$ 为邻居情绪均值，ρ 为传染强度系数。

信念更新机制。信念更新基于双通道信息输入：外部环境感知 P_t（推荐系统曝光内容和外部突发事件）与历史行为记忆 M_t。历史记忆采用流式记忆库存储，检索时使用同时兼顾时间衰减与语义相似度的加权打分函数：

$$R(m,t) = \alpha_{\text{rec}} e^{-\gamma(t-t_m)} + (1-\alpha_{\text{rec}}) \operatorname{sim}(q,m), \qquad (2)$$

其中 $\operatorname{sim}(\cdot,\cdot)$ 为基于预训练编码器的余弦相似度，$\alpha_{\text{rec}} \in [0,1]$ 控制“近因性”与“相关性”之间的权衡。在推理过程中，我们通过提示词显式引入确认偏差、锚定效应、情绪优先推理和简单归因倾向等认知偏差，以模拟真实人类认知中的系统性偏差。信念更新的整体形式为：

$$B_{t+1} = f_{\text{LLM}}(B_t, P_t, M_t, \Phi) \qquad (3)$$

其中 Φ 为嵌入提示词中的认知偏差引导。更新主要作用于 B^{evt} 和 B^{emo} 两个快速变化层，同时以较小步长缓慢调整 B^{psy} 中的心理认知信念，使其在长期尺度上随历史经验发生渐进演化；B^{id} 作为身份锚点在仿真过程中保持不变。

2) 欲望子系统: 欲望子系统承担动机生成器的角色——将信念状态转化为行为动机。社交媒体用户的参与动机高度多样化且因人而异，难以用固定规则覆盖，因此我们利用 LLM 的常识推理能力自动推断当前欲望集合。欲望集合采用带权重的多目标列表表示：

$$D_t = \{(d_1,w_1),(d_2,w_2),\ldots,(d_n,w_n)\}, \quad w_i \in [0,1] \qquad (4)$$

基于使用与满足理论，我们定义了七类典型欲望：情绪宣泄、娱乐消遣、自我表达、社交认同、社交连接、正义倡导和信息获取。欲望列表为意图子系统的行为规划提供动机约束——例如，当情绪宣泄欲望强度最高时，智能体更倾向于选择短评论和激烈的情感表达。欲望生成函数形式化为 $D_t = g_{\text{LLM}}(B_{t+1}, P_t)$。

3) 意图子系统: 意图子系统作为认知链路的最终决策环节，承担层级行为规划器的角色。POSIM 将社交媒体上的原子行为抽象为点赞、直接转发、转发带评论、评论以及原创博文等几类交互形式，而不再依赖精确的字数阈值来区分“长短”内容。与传统的单步行为生成不同，意图子系统采用多级思维链机制，将行为决策分解为三个递进的推理层级：

第一级——行为类别与目标对象选择：LLM 根据信念状态和欲望强度分布，从七种原子操作中选择行为类别，并确定目标对象（曝光内容、评论或热搜话题）。该层级决定做什么和对谁做。例如，当情绪宣泄欲望强度最高且愤怒情绪占主导时，智能体更倾向于选择短评论或转发带评论等能快速表达情绪的行为类型。

第二级——表达策略规划：（适用于需要生成文本内容的行为）在四个正交维度上规划表达策略——（a）*情绪维度*：主导情绪类型（愤怒、厌恶、焦虑、悲伤、兴奋、中性等）与强度等级（低/中/高/极端）；（b）*立场维度*：对目标主体的支持/反对/中立立场及其强度；（c）*风格维度*：理性分析、讽刺调侃、情绪攻击、共情理解、质疑求证等

表达风格；（d）*叙事维度*：事实罗列、标签化、行动呼吁、权威引用、阴谋论等叙事策略。该层级决定以何种方式表达。

第三级——内容生成：基于前两级决策的约束，生成符合角色特征的具体文本内容，包括正文、话题标签和 @ 提及。该层级决定具体说什么。例如，当第二级规划为高强度愤怒、反对立场、讽刺风格和标签化叙事时，生成的内容将呈现激烈的情绪表达、明确的反对态度和讽刺性的修辞手法。

这种三级分解设计具有两方面优势：其一，为内容生成提供了显式的策略约束，避免 LLM 在无引导下倾向于生成平均化的温和文本；其二，每一级的决策结果均被记录，使得行为的生成过程完全可追溯——研究者可从表达策略中分析为何智能体选择了特定的情绪基调或叙事手法。整体意图生成过程形式化为 $I_t = h_{\text{LLM}}(B_{t+1}, D_t, P_t)$，输出行为序列 $I_t = \{(a_j, o_j, s_j, c_j)\}_{j=1}^{m}$，其中 a_j 为行为类型，o_j 为目标对象，$s_j = (\text{emotion}, \text{stance}, \text{style}, \text{narrative})$ 为表达策略向量，c_j 为生成内容。单个智能体在每个决策周期内可生成 $m \geq 0$ 个行为，m 的值由 LLM 根据事件热度、情绪强度和用户活跃倾向自主决定。

4) 异质性智能体: 真实舆情演化涉及多类主体的复杂交互。基于元认知架构，我们定义了四种异质性智能体类型，它们共享同一套 EBDI 认知管线，但在角色约束和行为偏好上存在系统性差异：**普通网民**构成舆情参与的绝对主体，行为受个人信念和情绪主导，语言风格口语化，偏好短评论和点赞等轻量级交互；**意见领袖**具有较大影响力，决策更注重影响力维护和独立观点输出，活跃度最高；**媒体智能体**注重信息的时效性和权威性，以长博文为主，情绪表达克制；**政府智能体**代表官方立场，以高原创比例的长博文为核心行为形式。差异化行为通过角色特化提示词和行为参数差异化两个机制实现。

附录图 **??**展示了一个普通网民智能体在单个仿真步内的完整认知链路实例，涵盖从环境感知到信念更新、欲望生成、意图规划与行为执行的全过程，清晰展示了 EBDI 架构中各认知模块的输入-输出关系和信息流动。

C. 仿真环境

仿真环境是智能体感知和交互的虚拟社交媒体平台，其设计目标是在保持计算可行性的前提下忠实再现真实社交平台的信息流动机制和时间动力学特性。

1) 时间-事件混合驱动内核: 真实舆情事件中用户互动发生在分钟级时间尺度——一条爆炸性新闻可在数分钟内引发数千条转发，而在事件间歇期活跃度则大幅回落。传统的固定时间步长激活模式无法适应这种时间尺度的剧烈波动。为此，我们采用霍克斯自激点过程 作为群体活跃强度的生成模型。霍克斯过程的核心特性在于历史事件提升未来事件的发生概率，与舆情中热点事件激发参与、参与催生更多参与的正反馈机制高度吻合。如图 **??**右上角所示，条件强度函数定义为：

$$\lambda(t) = \mu + \sum_{t_i < t} \phi(t - t_i) \tag{5}$$

其中 μ 为基础活跃率，$\phi(t) = \alpha e^{-\beta t}$ 为指数衰减的激励核函数。激励项包含两类来源：（1）**外部事件刺激** ϕ_{ext}——外生舆情事件以较大的激励强度 α_{ext} 和较慢的衰减 β_{ext} 注入活跃度脉冲；（2）**内部活跃刺激** ϕ_{int}——用户行为本身以较弱的激励 $\alpha_{int} \ll \alpha_{ext}$ 和较快的衰减 $\beta_{int} \gg \beta_{ext}$ 产生二阶正反馈。为模拟社交媒体用户在工作日与夜间、工作日与周末之间的系统性活跃差异，我们进一步引入昼夜节律调制函数 $\lambda_{adj}(t) = \lambda(t) \cdot [(1-s) + s \cdot \text{circ}(h(t))]$：当 $\text{circ}(h(t))$ 在白天取高值、夜间取低值时，相同的外生事件在不同时段会诱发不同水平的集体响应，从而在无需额外脚本控制的情况下自然生成“白天高峰、夜间低谷”的日周期模式。

在每个时间步 Δt 内，系统根据调制后的强度采样当步需要激活的智能体数量：

$$N_t \sim \text{Poisson}\big(\lambda_{adj}(t)\, N_{\text{scale}}\big), \tag{6}$$

其中 N_{scale} 是将连续强度映射为期望激活人数的缩放系数。被激活的智能体通过加权采样确定，采样概率与其活跃度权重 $A(u_i)$ 成正比，

$$P(u_i \text{ activated}) \propto A(u_i), \tag{7}$$

其中 $A(u_i)$ 综合考虑用户长期发帖频率与社交影响力（如粉丝数量），并在 $[0, 1]$ 区间内进行归一化。该设计在保留“少数高活跃、高影响力用户更易被激活”的帕累托特征的同时，避免在论文中暴露过于工程化的细节。

2) 社交媒体推荐机制: 推荐算法是信息传播的守门人，决定了用户看到什么内容，进而影响其信念更新和行为决策。对于用户 u 和候选内容 p，曝光得分由三个维度加权组合：

$$S_{exp}(u, p) = \alpha \cdot H(u, p) + \beta \cdot P(p) + \gamma \cdot R(p) \tag{8}$$

其中 $H(u, p) = \cos(\mathbf{e}_u, \mathbf{e}_p)$ 为同质性得分，基于用户画像嵌入与内容嵌入的余弦相似度，模拟信息茧房效应——用户更容易看到与自身兴趣和立场相近的内容；$P(p)$ 为基于点赞、转发、评论等多维互动信号归一化得到的热度得分，用于刻画内容在全局范围内的受关注程度；$R(p) = e^{-\mu_r(t - t_p)}$ 为新鲜度得分，保证新内容获得曝光优势。语义嵌入采用 BGE-small-zh-v1.5 模型编码，并实施语义去重（余弦相似度 > 0.92 的内容视为重复）以避免信息冗余。

为平衡个性化推荐与信息多样性，候选内容按来源分为关注用户和非关注用户两个桶，按类型分为原创和转发两个桶，分桶独立排序后合并。系统保留 20% 的探索位用于随机推荐用户未接触过的内容，以抑制过度的信息茧房效应。每轮仿真中，智能体获取不超过 K 条推荐结果（默认 K=10），每条内容附带 N_c 条随机采样的评论（默认 N_c=5），模拟用户浏览评论区的行为。此外，系统根据仿真中涌现的话题标签自动统计热度（综合提及次数、互动量和时间衰减），定期更新热搜排行榜，上榜话题作为额外的信息曝光渠道呈现给智能体，模拟真实平台中热搜对舆情注意力聚焦的放大效应。

D. 策略推演框架

POSIM 不仅是一个仿真器，更是一个支持策略评估的实验平台。为支持舆情治理策略的定量评估和反事实分析，框架设计了事件队列、干预控制器和评估器构成的策略推演闭环。

事件队列是连接外部干预意图与仿真内部状态的统一接口。每个外部事件采用五元组表示 $E = \langle t, \tau, s, c, \iota \rangle$，涵盖用户级单点控制（指定智能体定时发布内容）和事件级全局广播（外部社会事件的全局传播）两个控制粒度。**干预控制器**提供运行时的多模态干预接口，包括注入新事件、修改智能体信念状态、调整推荐参数和控制节点行为约束。

基于状态快照机制，系统支持从任意时间步创建仿真分支，在同一基线的不同时间点注入不同干预事件，实现反事实策略的对比分析。**评估模块**与仿真引擎完全解耦，通过标准化数据接口读取仿真日志，独立计算多层次评估指标。

LLM 资源调度。大规模仿真涉及大量 LLM 调用，框架通过统一的 API 资源池管理多个 LLM 端点，支持多模型混合驱动和按用途路由——信念更新、欲望生成和行为决策三个认知阶段可分别指定不同规模的模型，兼顾推理质量与成本效率。资源池实现了端点级并发控制（信号量机制）、轮询式负载均衡、故障自动检测与转移以及调用频率限制，确保在高并发场景下的稳定运行。为避免 LLM 产生同质化输出，系统对每次调用的采样参数进行随机扰动：Temperature 扰动 $T' = T + \epsilon_T$，$\epsilon_T \sim \mathcal{U}(-0.1, 0.1)$；Top-p 扰动 $p' = p + \epsilon_p$，$\epsilon_p \sim \mathcal{U}(-0.05, 0.05)$；并随机注入频率惩罚和存在惩罚参数以增加词汇和话题多样性。

模块化架构。POSIM 采用高度解耦的模块化设计，智能体模块（认知架构与行为生成）、环境模块（推荐系统与热搜榜单）和策略推演模块（事件队列、干预控制与评估）三大核心模块相互独立，通过标准化接口通信。全局仿真参数（霍克斯过程参数、推荐权重、时间粒度等）通过统一的配置文件管理，支持不同舆情事件的快速适配。这一设计支持独立替换和扩展——例如，可以在不修改环境模块的前提下引入新的智能体认知架构，或在不修改智能体模块的前提下替换推荐算法。

IV. 实验

A. 实验设置

1) 数据集: 实验基于从新浪微博平台采集的三个具有代表性的大型社会舆情事件数据集展开。**天价耳环事件**（LE）：2025 年 5 月，演员黄杨钿甜成人礼照片中佩戴的绿色耳饰被网友指认为奢侈品牌耳环，引发公众对明星炫富与青少年价值观的争议；**武汉大学图书馆事件**（WL）：2025 年 1 月，武汉大学图书馆管理纠纷引发校园治理与学生权益的广泛讨论；**西贝预制菜事件**（XF）：2025 年 9 月，西贝莜面村预制菜争议引发公众对食品安全和消费者权益的持续关注。数据经过去重、低活跃用户过滤（事件期间发帖 <2 条）和无关内容清洗（广告、商业推广、不相关话题）后的描述性统计见表 **??**。仿真时间精度为 10 分钟/步。

智能体信念初始化。信念初始化直接决定了智能体的个性化程度。对于每个用户，基于其在仿真起始时间之前的历史发布内容，通过以下流程构建 EBDI 信念系统：（1）角色身份信念——将用户基础信息和历史内容摘要输入 LLM，生成第一人称角色描述；（2）心理认知信念——从涵盖八类典型网民心理模式的特征池中，基于历史内容的语义匹配进行个性化采样；（3）事件观点信念——通过 LLM 驱动的结构化深度访谈提取对各涉事主体的初始观点；（4）初始情绪向量——基于近期发布内容的情感分析结果初始化六维情绪向量。

2) 验证框架: 仿真系统的验证遵循三层递进框架：（1）**微观行为机制校准**（Verification）——验证智能体是否按照设计意图做出认知上可解释的决策；（2）**宏观现象涌现校准**（Emergence Validation）——验证微观机制能否涌现出符合社会科学理论预期的宏观现象；（3）**统计结果一致性校准**（Validation）——验证仿真输出是否在统计意义上准确再现真实舆情动态。三个层次构成从内部正确性、涌现合理性到外部准确性的完整验证链。

TABLE II
三个舆情事件数据集的描述性统计

事件	用户数	博文数	时长	仿真步数	类型
天价耳环 (LE)	1,530	34,218	∼46h	276	社会争议
武大图书馆 (WL)	1,843	51,647	∼190h	1,140	校园事件
西贝预制菜 (XF)	1,987	14,892	∼71h	426	食品安全

TABLE III
微观行为机制验证结果（均值 ± 标准差）

方法	认知行为链一致性 (0–5)↑	人格稳定性 (0–1)↑	认知鲁棒性 (0–1)↑
Direct-Nothink	1.47±0.50	0.478±0.263	0.629±0.240
Direct-Think	1.75±0.43	0.448±0.269	0.603±0.299
CoT	3.09±0.29	0.516±0.272	0.541±0.356
EBDI (Ours)	**4.64±0.48**	**0.661±0.215**	**0.695±0.213**

3) 对比方法: 微观验证设置四种决策方法：**Direct-Nothink**（轻量模型单次提示直接输出行为）、**Direct-Think**（较强模型单次提示直接输出）、**CoT**（单次调用内完成信念-欲望-行为的思维链串联）和 **EBDI**（本文方法，三阶段独立模块多步推理）。统计校准设置三种对比基线：**Rule-based ABM**（预定义规则驱动的传统仿真）、**POSIM w/o EBDI**（移除认知架构，LLM 单步决策）和 **POSIM w/ CoT**（将 EBDI 替换为单次思维链推理）。

B. 微观行为机制验证

微观验证旨在回答核心问题：EBDI 元认知架构是否使智能体具备了类人的、在认知与行为上可解释的决策能力？智能体在微观层面的行为机制一致性——即其决策是否遵循可理解的认知逻辑、是否保持人格稳定性、是否具备对输入扰动的认知鲁棒性——决定了宏观涌现结果的可信度基础。

实验基于天价耳环事件，随机抽取 $N = 100$ 名用户作为智能体，每名智能体具备从真实数据中初始化的身份描述、心理认知信念与行为倾向。仿真共进行 $T = 12$ 轮，四种方法在相同的事件背景、用户池和轮次下运行，仅决策接口与是否保留中间认知状态不同，以保证对比的公平性。评估阶段使用 Qwen2.5-14B-Instruct（temperature= 0.3）作为 LLM-as-Judge。三个评估维度的计算方式如下：（1）**认知行为链一致性**——将每个智能体在全部轮次的完整认知-行为记录提交评估 LLM，从认知链完整性、情绪动态合理性、动机-行为对齐度和信息整合能力四个子维度进行 0–5 分等级评分；（2）**人格稳定性**——评估 LLM 基于行为轨迹反推智能体的身份描述和行为倾向，与初始设定计算相似度（0–1）；（3）**认知鲁棒性**——对输入进行语义等价扰动（博文顺序打乱、随机删减、加入无关博文），每条原始决策对应 5 次扰动重复，评估核心决策稳定性和认知锚定强度（0–1）。结果见表 **??**。

认知行为链一致性采用 LLM-as-Judge 从认知链完整性、情绪动态合理性、动机-行为对齐度和信息整合能力四个子维度进行 0–5 分等级评分。EBDI 得分 4.64，显著高于 CoT 的 3.09 和 Direct 方法的 1.47–1.75，表明多步独立建模的认知架构在可解释性和认知深度上具有明显优势。**人格稳定性**通过让评估 LLM 从行为轨迹反推智能体的身份描述和行为倾向，并与初始设定计算相似度。EBDI 以

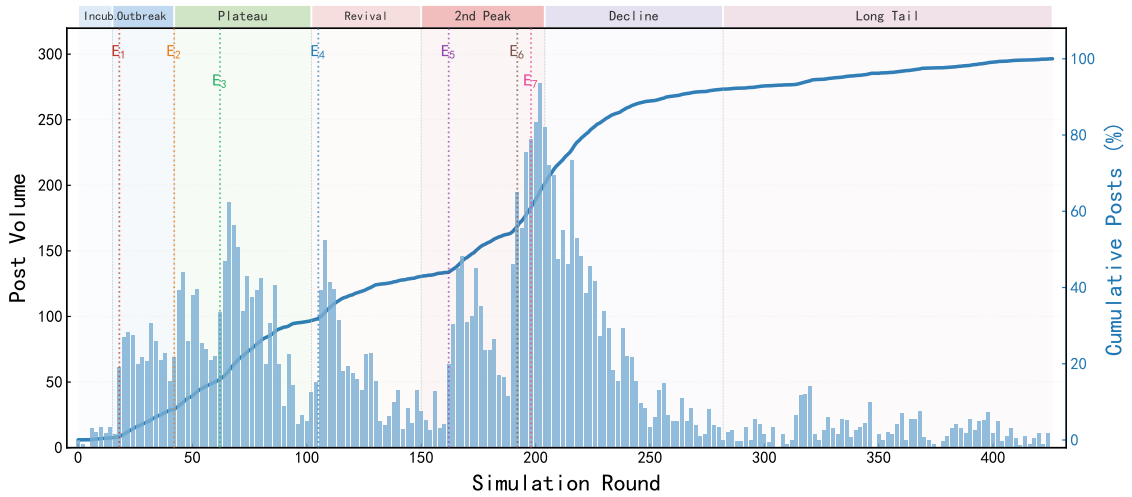

Fig. 2. 仿真舆情生命周期：发博量变化（柱状图，左轴）与累积发博百分比的观测 S 曲线（实线，右轴）及 Logistic 拟合曲线（虚线）。E_1–E_7 标记外生事件注入时间点。

0.661 的得分居于最高，因其可利用信念演化和情绪轨迹等丰富的中间状态信息。**认知鲁棒性**对输入进行语义等价扰动，评估决策是否由稳定的认知机制驱动。EBDI 以 0.695 的得分凭借显式的信念和欲望状态展现出认知锚定效应，核心决策在扰动下保持稳定。

综合三项指标，EBDI 在认知行为链一致性、人格稳定性和认知鲁棒性上均优于 CoT 和 Direct 基线，支持多步独立认知架构在微观层面的有效性。

C. 宏观现象涌现验证

微观验证确认了单个智能体的认知决策质量后，本节检验大量智能体交互时能否涌现出符合社会科学理论和真实舆情观察一致的宏观现象。我们以西贝预制菜事件（426 轮仿真、1,987 名智能体）为例，从四个维度进行验证。

1) 舆情生命周期: 如图 **??**所示，仿真清晰展现了舆情从爆发、平台、复燃到衰退的多阶段生命周期，且各阶段转换均可溯源至特定事件的因果驱动。E_1（食品卫生视频曝光）注入后发博量迅速攀升，E_2（罗永浩宣布停战）后活跃度明显回落；E_4（创始人群聊截图流出）重新点燃停战默契，E_5（三大央媒同日发声）触发全程最大活跃度，呈现典型的死灰复燃和央媒定调引发二次爆发的效应。从累积发博的 S 型曲线来看，实际观测值在平台期持续低于 Logistic 拟合、在复燃期显著高于拟合，呈阶梯式 S 型偏离，拐点与 E_5 高度吻合。

2) 多主体行为异质性: 图 **??**从情绪强度、内容长度和多维行为画像三个角度展示了四类智能体涌现出的系统性异质性。Citizen 和 KOL 的平均情绪强度分别为 0.645 和 0.603，始终处于高区间；Media 和 Government 则稳定在低唤醒区间，分别为 0.266 和 0.128，呈现公众情绪化、官方中性化的分层模式。内容长度呈阶梯分布：Media 最长，均值为 100.2 字；Government 次之，为 90.6 字；KOL 为 73.3 字；Citizen 最短，仅 43.4 字。雷达图上四类智能体形成了形态截然不同的多边形——Citizen 偏向情绪多样性和活跃度，KOL 最为均衡，Media 和 Government 集中在影响力、内容深度和原创比例上——直观证明了 EBDI 架构成功将差异化的角色设定转化为可辨识的宏观行为异质性。

TABLE IV
情绪唤醒理论验证指标

维度	指标	仿真结果	理论预期
唤醒自增强	高唤醒趋势系数 β	3.41×10^{-4} (p<0.001)	$\beta > 0$
	高唤醒情绪占比	73.5%	占主导
	高/低唤醒强度比	2.0×	> 1
情绪传染	评论链情绪一致率	0.772	$\gg$ 随机基线
	升级/降级比	4.78	> 1 (棘轮效应)

3) 情绪唤醒与极化效应: 基于 Berger 和 Milkman 的情绪唤醒理论和 Hatfield 等人 的情绪传染假说，我们从唤醒自增强和情绪传染两个维度进行验证（表 **??**）。

高唤醒情绪占比随仿真推进呈显著上升趋势，趋势系数 $\beta = 3.41\times10^{-4}$ 且 $p < 0.001$，总占比达 73.5%。高唤醒行为的平均情绪强度为 0.658，显著高于低唤醒行为的 0.328，差异倍率达 2.0×，与 Berger 和 Milkman 所预测的正反馈机制一致：高唤醒内容因传播优势获得更多曝光，进而激发更多高唤醒反应。在情绪传染方面，评论链中子评论与父帖的情绪一致率高达 0.772，远超随机基线。升级/降级比为 4.78，即由低唤醒转向高唤醒的概率是由高转低的近 5 倍，形成显著的棘轮效应，推动群体情绪不可逆地螺旋升级，支持 Hatfield 等人的情绪传染假说。

与此同时，我们定义极化指数 $\mathrm{PI} = 1 - H/H_{\max}$，其中 H 为各轮次的情绪 Shannon 熵，$H_{\max} = \log_2 K$（K 为情绪类别数）。PI 越高表示情绪分布越集中于少数类别。

如图 **??**所示，极化指数从早期的 0.41 攀升至晚期的 0.67（升幅 63%，$p < 0.001$），群体情绪从多元共存逐渐收敛为以少数高唤醒情绪主导的集中格局。该趋势与 Sunstein 的回音室理论一致：在信息推荐和社交互动的双重作用下，智能体逐渐被同质化的高唤醒情绪信息包围，情绪多样性不可逆地衰减。情绪极化与唤醒自增强共同构成了高唤醒驱动传播优势、进而导致多样性丧失的涌现因果链。

4) 无标度拓扑与级联幂律: 真实社交网络的度分布和信息级联规模普遍服从幂律分布，是无标度网络和长尾传播的标志性特征。我们构建了基于评论和转发关系的互动网络，检验仿真输出是否涌现出上述拓扑规律。

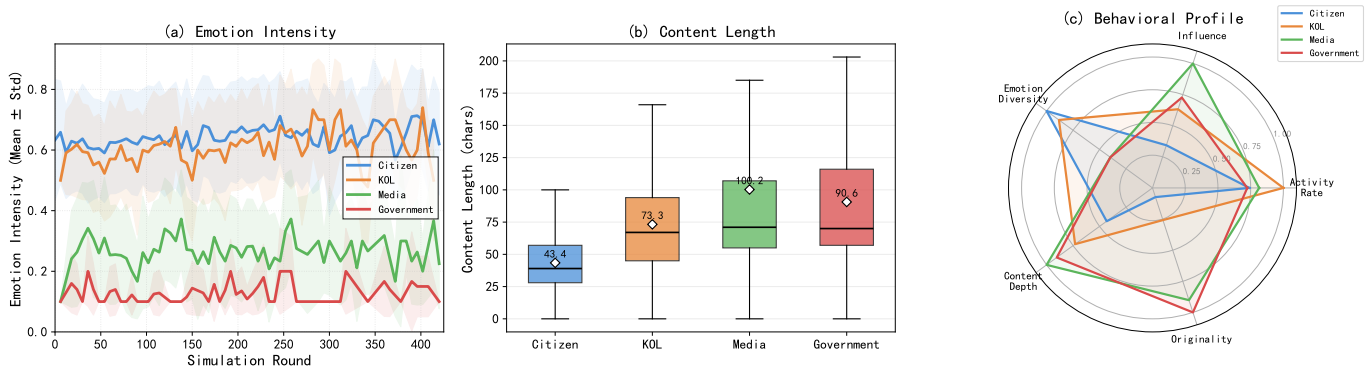

Fig. 3. 四类智能体行为异质性：(a) 情绪强度时序演化；(b) 内容长度分布；(c) 多维行为特征雷达图。

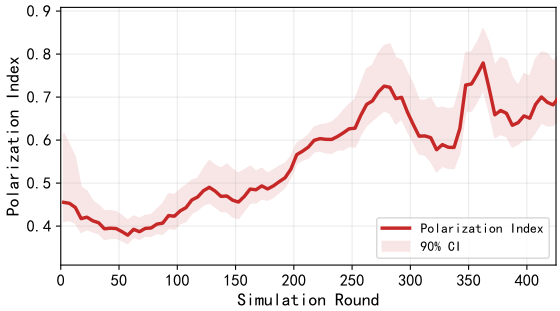

Fig. 4. 情绪极化指数（PI）随仿真轮次的演化。实线为 PI 均值，阴影为 90% Bootstrap 置信区间，虚线标注早期与晚期均值。

如图 **??**(a) 所示，互动网络的度分布在双对数坐标下呈良好线性关系，幂律拟合指数 $\gamma = 1.87$（$R^2 = 0.880$），表明网络具有无标度特性——少数节点获得了极高的度值（最大度 75），而大多数节点度值较低。该幂律指数落在真实社交网络中普遍报告的 $1.5 < \gamma < 3$ 范围内，且 Top-20% 用户贡献了 51.3% 的互动量，体现了帕累托分布特征。

如图 **??**(b) 所示，信息级联规模的 CCDF 在双对数坐标下同样呈线性衰减，$\alpha = 3.70$（$R^2 = 0.880$），拟合优度良好。5,473 个级联中，中位数规模仅为 1 但最大达 11，呈典型长尾效应——绝大多数内容获得有限传播，而少数内容形成相对大规模的级联。级联幂律指数 $\alpha > 2$ 与 Goel 等人 报告的有限病毒式传播特征一致，验证了仿真在信息传播动力学层面的保真度。

D. 统计结果校准

本节将仿真输出与三个真实舆情事件进行直接对比，从**行为层**（行为类型分布与活跃度曲线）、**内容层**（话语对抗性、词汇多样性与情感倾向）和**拓扑层**（网络结构与信息级联）三个维度进行系统性校准。

1) 评估指标: 为系统量化仿真与真实数据的一致性，我们设计了覆盖三个层面的评估指标体系。

行为层包含三个指标：（1）行为类型分布散度（BType JSD），采用 Jensen-Shannon 散度度量模拟与真实行为类型（原创、转发、评论）概率分布的差异：

$$\mathrm{JSD}(P\|Q) = \tfrac{1}{2}D_{\mathrm{KL}}(P\|M) + \tfrac{1}{2}D_{\mathrm{KL}}(Q\|M) \qquad (9)$$

其中 $M = \frac{1}{2}(P+Q)$，JSD 值越低表示越接近真实；（2）行为量曲线 Pearson 相关系数（Act. ρ），衡量模拟与真实的行为量时序曲线之间的趋势一致性；（3）行为量曲线 RMSE（Act. RMSE），衡量归一化后行为量曲线的绝对偏差。

内容层包含三个指标：（1）话语对抗性相似度（Confr. Sim.），通过关键词检测评估对抗性表达比率的差异 Confr. $= 1 - |c_{sim} - c_{real}|$；（2）词汇多样性偏差（$|\Delta\mathrm{TTR}|$），计算 Type-Token Ratio 的绝对差异，TTR 定义为唯一词元数与总词元数之比；（3）情感均值偏差（$|\Delta\bar{S}|$），计算模拟与真实内容情感极性均值的绝对差异。

拓扑层包含两个指标：（1）网络结构相似度（Net. Sim.），综合比较模拟与真实转发网络的入度分布、出度分布和网络密度等拓扑特征的加权相似度；（2）级联规模分布相似度（Casc. Sim.），将信息级联的规模分组为直方图，通过直方图交集度量分布一致性。各层平均得分（Avg.）对 ↓ 指标取 $1-x$ 后求均值。

2) 校准结果: 实验在三个真实舆情数据集上开展，结果如表 **??**和图 **??**所示。

行为层校准。行为层校准从行为类型分布和行为量时序曲线两个角度评估仿真与真实数据的一致性。POSIM 在三个数据集上的 BType JSD 均取得最优（LE: 0.193, WL: 0.073, XF: 0.148），说明 EBDI 元认知架构产生的行为决策在类型比例上与真实数据高度一致。值得注意的是，移除 EBDI 架构后（w/o EBDI），行为分布偏差显著增大，尤其在 XF 数据集上 JSD 从 0.148 升至 0.413，表明分层认知推理对行为决策的类型多样性起到了关键调控作用。在行为量曲线校准方面，POSIM 在所有数据集上均获得最高的 Pearson 相关系数和最低的 RMSE。w/ CoT 方法虽然引入了思维链推理，但由于缺乏信念-欲望-意图的分层建模，其行为层整体拟合精度仍低于完整的 POSIM 框架。行为层平均得分在三个数据集上分别达到 0.821、0.853 和 0.804，均为所有方法中最高。

内容层校准。内容层校准评估仿真生成内容与真实内容在话语对抗性、词汇多样性和情感倾向上的相似性。传统的 Rule-based ABM 由于仅使用模板化文本输出，内容层指标不适用，这恰恰凸显了 LLM 驱动的仿真方法在内容生成层面的本质优势。在 LLM 驱动方法的对比中，POSIM 的词汇多样性差异 $|\Delta\mathrm{TTR}|$ 在所有数据集上均最小（LE: 0.041, WL: 0.011），表明 EBDI 架构通过分层认知推理有效避免了平均人格问题，使得不同智能体产生差异化的文本输出。相比之下，w/o EBDI 方法的 TTR 偏差显著偏大，说明缺乏结构化认知建模时智能体的文本输出趋于同质化。在情感校准方面，POSIM 在 LE 数据集上实现了